

Lembar Kerja Praktikum 11

Projek - Praproses

Kelompok 6 - P1

Qois Firosi G6401231031

Aghnat Hasya Sayyidina G6401231074

Jason Bagaskara Mulyono G6401231088

Nugraha Darmaputra Tangkeallo G6401231105

Pada pertemuan praktikum kali ini, mahasiswa diarahkan untuk melanjutkan pengerjaan tugas akhir khususnya pada bagian *data preprocessing*. Tahapan ini mencakup proses pembersihan data (data cleaning), transformasi data, normalisasi, dan/atau encoding atribut jika diperlukan.

Tujuan Praktikum:

- Mahasiswa mampu menyelesaikan tahap praproses data pada proyek data mining masing-masing.
- Mahasiswa menunjukkan progres nyata dalam penyusunan laporan tugas akhir.

Tugas Praktikum:

1. Memulai pengerjaan laporan tugas akhir sesuai template (cek class)




Format Laporan Akhir Tugas Akhir Data Mining Genap 2024-2025

Mark as done

2. Membuat flow chart pengerjaan proyek mahasiswa
3. Menulis langkah-langkah praproses yang digunakan serta alasan penggunaan langkah tersebut
4. Visualisasi data awal dan hasil praproses
5. Memberikan interpretasi terhadap hasil praproses yang dilakukan
6. Mengisi sheet progress ([link](#))

Flow Chart Proyek



Langkah - Langkah praproses

NO	Langkah	Alasan
1	Normalisasi nama kolom (strip satuan (°C), ganti _to_ → _)	Merapikan konsistensi dan nama kolom menjadi lebih rapi dan gampang digunakan
2	parse_dates=["time"] + set index waktu	time series butuh DateTimeIndex
3	Memilih kolom yang diperlukan	Dataset memiliki banyak kolom (33) sehingga di
4	Cek missing value + duplikat	Validasi kualitas dataset
5	Deteksi outlier IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$)	Identifikasi nilai ekstrem (hujan deras dll) , namun dipertahankan karena cuaca ekstrem termasuk outlier
6	Resample daily data menjadi monthly	Cocok mengikuti periode musiman m=12, lebih ringan dibandingkan daily, dan lebih cocok untuk planting calendar

Visualisasi data awal dan hasil praproses

1. Normalisasi nama kolom (strip satuan (°C), ganti _to_ → _)

```
time, weather_code (wmo code), temperature_2m_mean (°C), temperature_2m_max (°C), temperature_2m_min (°C), apparent_temperature_min (°C), apparent_temperature_mean (°C), apparent_temperature_max (°C), sunrise (iso8601), sunset (iso8601), daylight_duration (s), sunshine_duration (s), precipitation_sum (mm), rain_sum (mm), snowfall_sum (cm), precipitation_hours (h), cloud_cover_mean (%), cloud_cover_max (%), cloud_cover_min (%), soil_moisture_0_to_100cm_mean (m³/m³), soil_moisture_0_to_7cm_mean (m³/m³), soil_moisture_28_to_100cm_mean (m³/m³), soil_moisture_7_to_28cm_mean (m³/m³), soil_temperature_0_to_100cm_mean (°C), soil_temperature_0_to_7cm_mean (°C), soil_temperature_28_to_100cm_mean (°C), soil_temperature_7_to_28cm_mean (°C), relative_humidity_2m_mean (%), relative_humidity_2m_max (%), relative_humidity_2m_min (%), surface_pressure_mean (hPa), pressure_msl_mean (hPa), dew_point_2m_mean (°C)
```

```
# normalisasi nama kolom,, hapus satuan dalam kurung & ubah '_to_' jadi '_'
df.columns = (df.columns
               .str.replace(r'\s*(.*)', '', regex=True)
               .str.replace('_to_', '_'))

# ambil kolom yang diperlukan
COL_TIME = 'time' # waktu (tanggal) 0
COL_WEATHER_CODE = 'weather_code' # kode cuaca (0-99) 1
COL_TEMP_2M_MAX = 'temperature_2m_max' # suhu maksimum 2 meter (°C) 2
COL_TEMP_2M_MEAN = 'temperature_2m_mean' # suhu rata-rata 2 meter (°C) 2
COL_TEMP_2M_MIN = 'temperature_2m_min' # suhu minimum 2 meter (°C) 3
COL_APPARENT_TEMP_MEAN = 'apparent_temperature_mean' # suhu terasa rata-rata (°C) 3
COL_SUNSHINE_DURATION = 'sunshine_duration' # durasi sinar matahari (s) 4
COL_CLOUD_COVER_MEAN = 'cloud_cover_mean' # tutupan awan rata-rata (%) 5
COL_PRECIPITATION_SUM = 'precipitation_sum' # jumlah presipitasi (mm) 5
COL_PRECIPITATION_HOURS_SUM = 'precipitation_hours' # jumlah jam presipitasi (jam) 6
COL_RAIN_SUM = 'rain_sum' # jumlah hujan (mm) 7
COL_SOIL_MOIST_0_7CM_MEAN = 'soil_moisture_0_7cm_mean' # kelembaban tanah 0-7 cm rata-rata (m³/m³) 8
COL_SOIL_TEMP_0_7CM_MEAN = 'soil_temperature_0_7cm_mean' # suhu tanah 0-7 cm rata-rata (°C) 9
COL_RELATIVE_HUMIDITY_2M_MEAN = 'relative_humidity_2m_mean' # kelembaban relatif 2 meter rata-rata (%) 10

FULL_COL = [COL_TIME, COL_WEATHER_CODE, COL_TEMP_2M_MAX, COL_TEMP_2M_MEAN, COL_TEMP_2M_MIN, COL_APPARENT_TEMP_MEAN,
             COL_SUNSHINE_DURATION, COL_CLOUD_COVER_MEAN, COL_PRECIPITATION_SUM, COL_PRECIPITATION_HOURS_SUM, COL_RAIN_SUM,
             COL_SOIL_MOIST_0_7CM_MEAN, COL_SOIL_TEMP_0_7CM_MEAN, COL_RELATIVE_HUMIDITY_2M_MEAN]
```

Kolom pada dataset masih memiliki satuan dan spasi. Dilakukan normalisasi dengan menghapus kurung, spasi, dan satuan sehingga nama kolom menjadi lebih konsisten dan

mudah digunakan. Selain itu, setiap nama kolom dijadikan constant variable untuk memudahkan referensi dan menghindari typo dalam coding proyek lanjutan.

2. Set index ke waktu dan memilih kolom yang diperlukan saja

```
FULL_COL = [COL_TIME, COL_WEATHER_CODE, COL_TEMP_2M_MAX, COL_TEMP_2M_MEAN, COL_TEMP_2M_MIN, COL_APPARENT_TEMP_MEAN, COL_SUNSHINE_DURATION, COL_CLOUD_COVER_MEAN, COL_PRECIPITATION_SUM, COL_PRECIPITATION_HOURS_SUM, COL_RAIN_SUM, COL_SOIL_MOIST_0_7CM_MEAN, COL_SOIL_TEMP_0_7CM_MEAN, COL_RELATIVE_HUMIDITY_2M_MEAN]

df = df[FULL_COL]
df = df.set_index('time')
df.index.freq = 'D' # set daily frequency
print(f' Dataset dimuat: {df.shape[0]:,} baris {df.shape[1]} kolom')
print(f' Rentang waktu : {df.index.min().date()} -> {df.index.max().date()}')
```

Dari raw 33 kolom dataset, dipilih 13 kolom yang relevan dengan tujuan dari proyek. Selain itu, index dari dataset diubah ke waktu agar cocok dengan time-series.

3. Cek missing value dan duplikasi

```
# Analisis Missing Value dan duplikasi

mv = pd.DataFrame({
    'Jumlah Missing': df.isnull().sum(),
    'Persen (%)': (df.isnull().mean() * 100).round(2)
}).sort_values('Persen (%)', ascending=False)

mv_nonzero = mv[mv['Jumlah Missing'] > 0]
print(f'Kolom dengan missing value: {len(mv_nonzero)} dari {df.shape[1]}')
display(mv_nonzero.style.background_gradient(subset=['Persen (%)'], cmap='Reds').format({'Persen (%)': '{:.2f}%'}))

dup_count = df.duplicated().sum()
print(f'Jumlah baris duplikat: {dup_count}')
```

[0] Python

... Kolom dengan missing value: 0 dari 13

Jumlah Missing	Persen (%)
----------------	------------

... Jumlah baris duplikat: 0


Dataset yang sudah diolah sebelumnya dilakukan cek missing values dan duplicated values untuk melihat apakah ada data harian cuaca yang kurang ataupun ada yang duplicate.

4. Deteksi Outlier




Deteksi outlier untuk identifikasi nilai ekstrim.

5. Resample data harian menjadi data bulanan



Data yang ada di dataset merupakan data harian, untuk meringankan komputasi dan memudahkan dalam pemodelan SARIMAX. Data diaggregasi menjadi data bulanan dengan mengambil rata - rata setiap bulannya.



Interpretasi

- Tidak ada missing value & tidak ada duplikat, data yang didapat dari sumber termasuk data yang bersih.
- Tidak digunakan encoding karena fitur yang diprediksi pada data sudah merupakan fitur numerik
- Berdasarkan EDA, Outlier tidak dihapus karena merupakan fenomena cuaca ekstrem yang dapat terjadi
- Resample data harian menjadi bulanan untuk meringankan komputasi dan lebih menekankan pada prediksi variable rata - rata bulanan. Dan juga menghindari noise harian.