

PRAKTIKUM 10 — DATA MINING

Progres Projek: Analisis Data Eksploratif (EDA)

Climate Forecasting as Support for Planting Calendar

Studi Kasus: Kota Bogor, 1940–2025

Kelompok 6 - P1
Departemen Ilmu Komputer

11 May 2026

Daftar Isi

Judul Proyek	3
Sumber Data	3
Penjelasan Data	3
Langkah Pembacaan Data	4
Pembacaan & Normalisasi Kolom	4
Verifikasi Pemuatan	4
Bentuk Eksplorasi Data & Hasil	5
Statistik Deskriptif	5
Analisis Missing Value & Duplikasi	5
Distribusi Variabel & Deteksi Outlier	6
Visualisasi Deret Waktu (1940–2025)	7
Dekomposisi STL (Trend / Seasonal / Residual) Bulanan	9
Pola Musiman (Boxplot per Bulan)	12
Korelasi Antar Fitur (Pearson)	13
Deteksi Outlier (IQR)	14
Tren Iklim Jangka Panjang (Per Dekade)	14
Klasifikasi Iklim Oldeman	14
Interpretasi Akhir EDA	15

Judul Proyek

Climate Forecasting as Support for Planting Calendar

Pemodelan deret waktu data iklim historis Kota Bogor (1940–2025) untuk mendukung rekomendasi kalender tanam padi. Proyek dibangun dengan target prediksi 4 variabel iklim utama (suhu udara, curah hujan, kelembaban tanah, dan suhu tanah) menggunakan model SARIMAX, lalu diturunkan menjadi keputusan kesesuaian tanam.

Keputusan kesesuaian tanam diperoleh dari studi literatur mengenai pengaruh seperti suhu tanah, kelembapan udara, suhu udara dan intensitas hujan terhadap kesesuaian dalam penanaman padi.

Sumber Data

Dataset diperoleh dari **Open-Meteo Historical Weather API**, layanan data cuaca historis gratis berbasis *ERA5 reanalysis* (ECMWF).

URL API	https://open-meteo.com/en/docs/historical-weather-api
Lokasi	Bogor (Lat: -6.5944 , Long: 106.7892)
Periode	1 Januari 1940 — 31 Desember 2025 (86 tahun)
Granularitas	Harian (daily)
Format	CSV
Ukuran	31.411 baris $\times$ 13 kolom (setelah seleksi atribut, exclude ‘time’)

Karena rate-limit API, data diakuisisi bertahap per ~ 20 tahun (1940–1960, 1960–1980, 1980–2000, 2000–2026) lalu digabungkan menjadi satu dataset utuh `merged_dataset-1940-2025-bogor.csv`.

Penjelasan Data

Dataset berisi observasi cuaca harian. Setelah seleksi, 13 atribut numerik dipertahankan untuk analisis (tabel di bawah). Atribut yang tidak relevan untuk wilayah tropis (mis. `snowfall_sum`) dan atribut redundan dihilangkan.

#	Atribut	Satuan	Deskripsi
1	<code>time</code>	date	Tanggal observasi (YYYY-MM-DD)
2	<code>weather_code</code>	WMO	Kode kondisi cuaca standar WMO
3	<code>temperature_2m_max</code>	$^{\circ}\text{C}$	Suhu udara maksimum harian (2m)
4	<code>temperature_2m_mean</code>	$^{\circ}\text{C}$	Suhu udara rata-rata harian (2m)
5	<code>temperature_2m_min</code>	$^{\circ}\text{C}$	Suhu udara minimum harian (2m)
6	<code>apparent_temperature_mean</code>	$^{\circ}\text{C}$	Suhu terasa rata-rata (<i>feels-like</i>)
7	<code>sunshine_duration</code>	s	Durasi sinar matahari efektif
8	<code>cloud_cover_mean</code>	%	Tutupan awan rata-rata
9	<code>precipitation_sum</code>	mm	Total curah hujan harian
10	<code>precipitation_hours</code>	jam	Jumlah jam hujan dalam sehari
11	<code>rain_sum</code>	mm	Total curah hujan cair harian
12	<code>soil_moisture_0_7cm_mean</code>	m^3/m^3	Kelembaban tanah lapisan permukaan (0–7 cm)

13	soil_temperature_0_7cm_mean	°C	Suhu tanah lapisan permukaan (0–7 cm)
14	relative_humidity_2m_mean	%	Kelembaban relatif udara (2m)

Langkah Pembacaan Data

Pembacaan & Normalisasi Kolom

```
DATASET_PATH = 'dataset/merged_dataset-1940-2025-bogor.csv'
df = pd.read_csv(DATASET_PATH, parse_dates=['time'])
```

```
# normalisasi nama kolom,, hapus satuan dalam kurung & ubah '_to_' jadi '_'
df.columns = (df.columns
               .str.replace(r'\s*\(.*\)', '', regex=True)
               .str.replace('_to_', '_'))
```

```
# ambil kolom yang diperlukan
```

```
COL_TIME = 'time' # waktu (tanggal) 0
COL_WEATHER_CODE = 'weather_code' # kode cuaca (0-99) 1
COL_TEMP_2M_MAX = 'temperature_2m_max' # suhu maksimum 2 meter (°C) 2
COL_TEMP_2M_MEAN = 'temperature_2m_mean' # suhu rata-rata 2 meter (°C) 2
COL_TEMP_2M_MIN = 'temperature_2m_min' # suhu minimum 2 meter (°C) 3
COL_APPARENT_TEMP_MEAN = 'apparent_temperature_mean' # suhu terasa rata-rata (°C) 3
COL_SUNSHINE_DURATION = 'sunshine_duration' # durasi sinar matahari (s) 4
COL_CLOUD_COVER_MEAN = 'cloud_cover_mean' # tutupan awan rata-rata (%) 5
COL_PRECIPITATION_SUM = 'precipitation_sum' # jumlah presipitasi (mm) 5
COL_PRECIPITATION_HOURS_SUM = 'precipitation_hours' # jumlah jam presipitasi (jam) 6
COL_RAIN_SUM = 'rain_sum' # jumlah hujan (mm) 7
COL_SOIL_MOIST_0_7CM_MEAN = 'soil_moisture_0_7cm_mean' # kelembaban tanah 0-7 cm rata-rata (m³/m³) 8
COL_SOIL_TEMP_0_7CM_MEAN = 'soil_temperature_0_7cm_mean' # suhu tanah 0-7 cm rata-rata (°C) 9
COL_RELATIVE_HUMIDITY_2M_MEAN = 'relative_humidity_2m_mean' # kelembaban relatif 2 meter rata-rata (%) 10
```

```
FULL_COL = [COL_TIME, COL_WEATHER_CODE, COL_TEMP_2M_MAX, COL_TEMP_2M_MEAN,
             COL_TEMP_2M_MIN, COL_APPARENT_TEMP_MEAN,
             COL_SUNSHINE_DURATION, COL_CLOUD_COVER_MEAN, COL_PRECIPITATION_SUM,
             COL_PRECIPITATION_HOURS_SUM, COL_RAIN_SUM,
             COL_SOIL_MOIST_0_7CM_MEAN, COL_SOIL_TEMP_0_7CM_MEAN,
             COL_RELATIVE_HUMIDITY_2M_MEAN]
```

```
df = df[FULL_COL]
df = df.set_index('time')
df.index.freq = 'D' # set daily frequency
```

Verifikasi Pemuatan

Jumlah baris	31.411
Jumlah kolom	13 (setelah seleksi)
Rentang waktu	1940-01-01 → 2025-12-31

Bentuk Eksplorasi Data & Hasil

Statistik Deskriptif

Setiap kolom numerik dihitung statistik dasar (`describe`) ditambah **koefisien variasi (CV%)** dan **range**. CV digunakan untuk membandingkan tingkat variasi antar variabel berdimensi berbeda.

```
desc = df.describe().T
desc['cv%'] = (desc['std'] / desc['mean'] * 100).round(2) # koefisien variasi
desc['range'] = desc['max'] - desc['min']
display(desc.style
         .format(precision=3))
```

Hasil utama:

Variabel	Mean	Std	CV %
temperature_2m_mean	~24,7 °C	0,9	3,7%
sunshine_duration	~35.000 s (9,7 jam)	8.839	25%
precipitation_sum	~7,141	7,94	111%
rain_sum	~7,141	7,94	111%
precipitation_hours	~9 jam	5,6	62%

Interpretasi:

- `temperature_2m_mean` memiliki **CV coefficient of variation rendah** 3,7 % → suhu Bogor sangat stabil sepanjang tahun
- `sunshine_duration` rata rata adalah 35000 detik ($\approx$ 9,7 jam) dengan variasi yang cukup beragam (25%)
- `precipitation_sum` memiliki **CV coefficient of variation tinggi** (111 %) → curah hujan sangat bervariasi
- `rain_sum` sama dengan `precipitation_sum` (sumber air dari hujan saja, tidak ada dari salju dll)
- `precipitation_hours` rata-rata 9 jam dengan variasi tinggi (CV 62 %) → hujan bisa sangat singkat atau berlangsung lama
- `soil temperature`, `soil moisture`, dan `relative humidity` menunjukkan variasi yang lebih rendah

Analisis Missing Value & Duplikasi

Analisis Missing Value dan duplikasi


```
mv = pd.DataFrame({
    'Jumlah Missing': df.isnull().sum(),
    'Persen (%)': (df.isnull().mean() * 100).round(2)
}).sort_values('Persen (%)', ascending=False)

mv_nonzero = mv[mv['Jumlah Missing'] > 0]
print(f'Kolom dengan missing value: {len(mv_nonzero)} dari {df.shape[1]}')
display(mv_nonzero.style.background_gradient(subset=['Persen (%)'],
                                              cmap='Reds').format({'Persen (%)': '{:.2f}%'}))

dup_count = df.duplicated().sum()
print(f'Jumlah baris duplikat: {dup_count}')
```

Hasil: Dataset ini tidak memiliki missing value dan duplikasi.


Distribusi Variabel & Deteksi Outlier



Gambar 1: Distribusi Variabel

Temuan:

- Suhu (`temperature_2m_*`) — distribusi mendekati normal, simetris.
- Curah hujan (`precipitation_sum`, `rain_sum`) — positive skewed, banyak nilai nol & ekor panjang (hari hujan ekstrem)
- `cloud_cover_mean` — distribusi cenderung negative skewed (langit umumnya berawan).
- `sunshine_duration` — negative skewed, cenderung memiliki durasi penyinaran sinar matahari yang cukup
- `precipitation_hours` — distribusi mendekati normal dengan nilai 0 yang banyak (saat musim kemarau / bulan kering). Dengan tidak adanya outlier.
- `soil_moisture` dan `relative_humidity` cenderung berdistribusi negative skewed, dimana tanah dan relatif kelembaban termasuk lembab




Gambar 2: Visualisasi Box Plot

Visualisasi Deret Waktu (1940–2025)


Tiga *line plot* harian + *rolling 365 hari* + tren linear `np.polyfit`:

- Suhu udara rata-rata (`temperature_2m_mean`)




Gambar 3: Tren suhu udara rata rata

- Curah hujan harian (`precipitation_sum`)




Gambar 4: Tren curah hujan

- Kelembaban tanah (`soil_moisture_0_7cm_mean`)



Gambar 5: Tren kelembapan tanah

- Kelembaban udara (`relative_humidity`)




Gambar 6: Tren kelembapan udara

- **Suhu** — tren linear **meningkat** secara konsisten dari. Indikasi adanya global warming dan pemanasan bumi.
- **Curah hujan** — tren linear hampir datar
- **Kelembaban tanah dan udara** — relatif stabil dengan variasi musiman tahunan, dengan penurunan tren di tahun 2010++

Dekomposisi STL (Trend / Seasonal / Residual) Bulanan

Resample bulanan → STL `period=12, robust=True` untuk 4 series: suhu, hujan, kelembaban tanah, kelembaban udara.


```
df_monthly = df[...].resample('ME').mean()
stl = STL(series, period=12, robust=True).fit()
# .observed / .trend / .seasonal / .resid
```




Gambar 7: Dekomposisi suhu rata - rata



Gambar 8: Dekomposisi curah hujan



Gambar 9: Tren kelembapan tanah



Gambar 10: Tren kelembapan udara


Temuan:

- **Suhu** — *trend* naik halus 1940→2025 ($+ \approx 1\text{ }^{\circ}\text{C}$); *seasonal* amplitudo kecil (siklus tahunan lemah, ciri tropis).
- **Curah hujan** — terdapat *trend* yang fluktuatif (musim kemarau, musim hujan)
- **Kelembaban tanah** — *seasonal* jelas mengikuti pola hujan; *trend* stabil.

- **Kelembaban udara** — pola serupa kelembaban tanah, mengikuti musim hujan.

Pola Musiman (Boxplot per Bulan)


Boxplot tiap variabel di-*grup* per bulan (Januari – Desember):



Gambar 11: Pola Musiman

- **Musim Hujan (Okt–Apr)** — curah hujan harian rata-rata > 10 mm, kelembaban $> 85\%$, suhu sedikit lebih rendah. Cocok untuk penanaman padi standar.
- **Musim Kemarau (Mei–Okt)** — curah hujan < 5 mm/hari, *sunshine duration* lebih panjang. Periode ini hanya cocok untuk padi jika tersedia irigasi atau penanganan air yang baik.

Korelasi Antar Fitur (Pearson)



Gambar 12: Korelasi Person


Korelasi:

- `temperature_2m_mean` $\approx$ `apparent_temperature_mean` ($\sim +0,95$) — redundan.
- `precipitation_sum` $\approx$ `rain_sum` ($\sim +1,0$) — identik untuk wilayah tropis.
- `cloud_cover_mean` $\leftrightarrow$ `sunshine_duration` ($\sim -0,8$) — semakin berawan, semakin sedikit sinar matahari yang menyinari.
- `relative_humidity_2m_mean` $\leftrightarrow$ `temperature_2m_mean` ($\sim -0,6$) — udara panas cenderung lebih kering.
- `precipitation_hours` $\leftrightarrow$ `precipitation_sum` ($\sim +0,7$) — lama hujan, terakumulasi.
- `soil_moisture` $\leftrightarrow$ `precipitation_sum` ($\sim +0,3$ s.d. $+0,5$) — hujan menjadikan tanah lebih basah -> kelembaban lebih

Implikasi modelling:

- Fitur kandidat *exogenous* SARIMAX, dimana variable external mempengaruhi target variable tapi tidak sebaliknya : `relative_humidity_2m_mean`, `sunshine_duration`, `cloud_cover_mean`, `precipitation_hours`.


Deteksi Outlier (IQR)



Gambar 13: Deteksi Outlier Boxplot

outlier pada `precipitation_sum` bukan error, melainkan dapat diinterpretasi kejadian hujan ekstrem (banjir, badai). Tidak dihapus, tetapi dapat dipertimbangkan transformasi (log/Box-Cox) atau penanganan robust pada saat modelling.

Tren Iklim Jangka Panjang (Per Dekade)



Gambar 14: Tren iklim perdekade

Temuan:


- **Suhu rata-rata per dekade naik konsisten** dari ~24,4 °C (1940-an) menuju ~25,8 °C (2020-an), indikasi adanya pemanasan global.
- **Kelembaban udara relatif** sedikit menurun seiring suhu naik.

Klasifikasi Iklim Oldeman

Menerapkan klasifikasi **Oldeman** berbasis akumulasi hujan bulanan:

Kategori	Kriteria
Bulan Basah (BB)	$\text{hujan} \geq 200 \text{ mm/bulan}$
Bulan Lembab (BL)	$100 \leq \text{hujan} < 200 \text{ mm/bulan}$
Bulan Kering (BK)	$\text{hujan} < 100 \text{ mm/bulan}$

```
def classify_oldeman(mm):
    if mm >= 200: return 'Bulan Basah (BB ≥ 200 mm)'
    elif mm >= 100: return 'Bulan Lembab (BL 100–200 mm)'
    else: return 'Bulan Kering (BK < 100 mm)'
```



Gambar 15: Klassifikasi oldeman

Rata-rata bulanan jangka panjang menunjukkan **9+ Bulan Basah berturut-turut** (Oktober – April mendominasi BB), dengan bulan lembab dan kering dominasi di Juni - September.

- Bogor tergolong **Tipe Iklim A** (Oldeman) — > 9 Bulan Basah berturut-turut.
- **Okt–Apr**: dominan Bulan Basah (> 200 mm) → kondisi sangat mendukung tanam padi; risiko banjir di puncak hujan.
- **Jun–Agu**: cenderung Bulan Lembab–Kering → bergantung ketersediaan irigasi.
- **Rekomendasi musim tanam padi**: MT1 = Oktober–Maret, MT2 = April–September (dengan irigasi yang baik).

Interpretasi Akhir EDA

Ringkasan temuan EDA:

1. **Stabilitas suhu, variabilitas hujan.** Suhu Bogor sangat stabil (CV 3,7%) sementara curah hujan sangat bervariasi (CV 111%). Modelling perlu memperlakukan dua jenis sinyal ini berbeda, suhu lebih mudah diprediksi, hujan butuh model yang menangani *spike* ekstrem.
2. **Pola musiman kuat pada hujan & kelembaban.** STL & boxplot bulanan menunjukkan siklus tahunan ($m = 12$). Pemilihan model SARIMAX cocok dengan komponen musiman bulanan untuk tahap berikutnya.
3. **Tren pemanasan jangka panjang.** Suhu rata-rata secara dekade meningkat dari 1940-an ke 2020-an, perlu diperhatikan untuk rekomendasi kalender tanam ke depan.
4. **Redundansi kolom** `rain_sum` $\approx$ `precipitation_sum`; `temperature_2m_mean` $\approx$ `apparent_temperature_mean`. Salah satu dari tiap pasangan akan didrop pada tahap feature engineering.
5. **Kandidat exogenous SARIMAX.** `relative_humidity_2m_mean`, `sunshine_duration`, `cloud_cover_mean`, `precipitation_hours`.